

Univerza v Ljubljani

Fakulteta za elektrotehniko

Stojan Budjak

ZAZNAVANJE IN MANIPULACIJA DEFORMABILNIH OBJEKTOV Z ROBOTOM

Diplomsko delo

Univerzitetni študijski program prve stopnje Elektrotehnika

Mentor: prof. dr. Matjaž Mihelj

Somentor: asist. dr. Sebastjan Šlajpah

Ljubljana, 2024

Št. teme: 00243 / 2023

Datum prijave: 18. 10. 2023

Univerza v Ljubljani, Fakulteta za elektrotehniko izdaja naslednjo nalogo:

Kandidat: **Stojan Budjak**

Naslov: **Zaznavanje in manipulacija deformabilnih objektov z robotom**
Robot-based detection and manipulation of deformable objects

Vrsta naloge: Diplomsko delo
Univerzitetni študijski program prve stopnje Elektrotehnika

Tematika naloge:

Razvijte sistem za robotsko manipulacijo deformabilnih objektov, ki se premikajo po tekočem traku. Robotski sistem naj vključuje robotski manipulator, orodje za zarezovanje, tekoči trak in globinsko kamero. Predlagajte metodo za izračun geometrijskih parametrov in lege objekta na tekočem traku na podlagi oblaka točk, pridobljenega z globinsko kamero. Z znano lego in geometrijo objekta načrtajte trajektorije robota za izvedbo manipulacije. Robot naj med manipulacijo sinhronizirano sledi gibanju tekočega traku. Sistem validirajte v laboratorijskem okolju.

Ljubljana, 2. 9. 2024

prof. dr. Matjaž Mihelj
Mentor

prof. dr. Janko Drnovšek
Predstojnik katedre

asist. dr. Sebastjan Šlajpah
Somentor



prof. dr. Marko Topič
dekan

M. Topič


Spodaj podpisani študent, Stojan Budjak, vpisna številka 64210384, avtor pisnega zaključnega dela študija z naslovom: Zaznavanje in manipulacija deformabilnih objektov z robotom,

IZJAVLJAM,

1. ¹ a) da je pisno zaključno delo študija rezultat mojega samostojnega dela;
b) da je pisno zaključno delo študija rezultat lastnega dela več kandidatov in izpolnjuje pogoje, ki jih Statut UL določa za skupna zaključna dela študija ter je v zahtevanem deležu rezultat mojega samostojnega dela;
2. da sem pridobil vsa potrebna dovoljenja za uporabo podatkov in avtorskih del v pisnem zaključnem delu študija in jih v pisnem zaključnem delu študija jasno označil;
3. da sem pri pripravi pisnega zaključnega dela študija ravnal v skladu z etičnimi načeli in, kjer je to potrebno, za raziskavo pridobil soglasje etične komisije;
4. da soglašam z uporabo elektronske oblike pisnega zaključnega dela študija za preverjanje podobnosti vsebine z drugimi deli s programsko opremo za preverjanje podobnosti vsebine, ki je povezana s študijskim informacijskim sistemom članice;
5. da na UL neodplačno, neizključno, prostorsko in časovno neomejeno prenašam pravico shranitve avtorskega dela v elektronski obliki, pravico reproduciranja ter pravico dajanja pisnega zaključnega dela študija na voljo javnosti na svetovnem spletu preko Repozitorija UL;
6. da dovoljujem objavo svojih osebnih podatkov, ki so navedeni v pisnem zaključnem delu študija in tej izjavi, skupaj z objavo pisnega zaključnega dela študija.
7. da dovoljujem uporabo mojega rojstnega datuma v zapisu COBISS.

V: Ljubljani
Datum: 2. 9. 2024

Podpis študenta:



¹ Obkrožite varianto a) ali b).

Zahvala

Најголемото благодарам му припаѓа на моето семејство. Ви благодарам што ми го овозможивте ова патување, Ви благодарам за неизмерната поддршка низ моите студентски денови, Ви благодарам што бевте ветерот кој тивко ме удира во грбот. Овој успех не е само мој успех, туку најмногу ваш.

Na začetku bi rad izrazil hvaležnost prof. dr. Matjažu Mihlju za podporo, vodstvo in odzivnost med pripravo diplomskega dela. Njegovo strokovno znanje in usmerjanje so bili ključnega pomena pri razvoju in uspešno izvedbo tega dela.

Posebno zahvalo namenjam tudi somentorju, as. dr. Sebastjanu Šlajpahu, za dragocene nasvete in usmerjanje pri praktičnem delu diplomskega dela. Njegova strokovnost je bistveno prispevala k celovitosti in kakovosti mojega dela.

Iskreno se zahvaljujem tudi Fakulteti za elektrotehniko za vse pridobljene izkušnje v preteklih letih, ki so bile ključne pri ustvarjanju tega dela. Prav tako bi rad izrazil zahvalo prijateljem za njihovo stalno moralno podporo tekom pisanja in obdelave diplomske naloge.

Povzetek

V diplomski nalogi smo raziskovali uporabo robota UR5e, kamere Visionary-T in tekočega traku za avtomatizirano zarezovanje krušnega testa. Cilj raziskave je bil razviti učinkovit in natančen sistem za zarezovanje testa, ki bi povečal produktivnost in zmanjšal potrebo po ročnem delu v pekarnah.

Sistem je sestavljen iz treh glavnih komponent: robota UR5e za natančno rezanje, kamere Visionary-T za pridobivanje oblakov točk krušnega testa in tekočega traku za transport kruha skozi proces. Uporabili smo tudi računalnik za obdelavo oblakov točk, pri čemer smo uporabljali programski jezik Python.

Komponente sistema so povezane v laboratorijsko omrežje prek Ethernet povezave in komunicirajo prek TCP/IP protokola. Kamera Visionary-T je priključena na robota UR5e. Ko laser na tekočem traku zazna testo, se trak zaustavi, kamera pa zajame oblak točk, ki ga prek FTP protokola pošlje na računalnik.

Računalnik obdeluje oblak točk z algoritmom, ki vključuje odstranjevanje izstopajočih točk (ang. *statistical outlier removal*) in odstranjevanje ravnine z naključnim vzorčnim konsenzom (ang. *Random Sample Consensus, RANSAC*). Koeficiente ravnine določimo ročno glede na postavitev kamere Visionary-T. Nato se oblak točk zglati in z analizo glavnih komponent (ang. *Principal Component Analysis, PCA*) določijo osi. Na tej točki se tudi izmerijo dimenzije testa in oblikuje optimalna škatla v obliki kvadra za krušno testo. Glede na uporabnikove zahteve se določita kot rezanja in število linij zarezovanja, oziroma uporabnik nastavi, kako naj se krušno testo zareže. Vsaka določena točka vsebuje tri koordinate (x, y, z) , ki se pošljejo robotu po ustrezni kalibraciji, saj kamera in robot uporabljata različna koordinatna sistema. Za namen te raziskave smo določili tri linije zarezovanja, kar pomeni 18 točk ($3 \text{ linije} \times 2 \text{ točki} \times 3 \text{ koordinate}$).

Ko robot prejme te točke, se trak ponovno zažene in robot začne z zarezovanjem krušnega testa. Sistem omogoča prilagoditev načina zarezovanja prek računalnika, kar omogoča različne oblike in vzorce zarezovanja testa.

Raziskava je bila izvedena eksperimentalno, z integracijo in optimizacijo delovanja vseh komponent. Glavne ugotovitve vključujejo večjo natančnost zarezovanja krušnega testa, zmanjšanje odpadkov in povečanje hitrosti proizvodnje. Sistem je prilagodljiv za različne vrste in velikosti kruha, kar dodatno prispeva k njegovi uporabnosti v pekarnah.

Ključne besede: robotika, avtomatizacija, UR5e, Visionary-T, tekoči trak, obdelava oblakov točk, kalibracija, avtomatizirano zarezovanje testa.

Abstract

In this thesis, we investigated the use of the UR5e robot, the Visionary-T camera, and a conveyor belt for automated bread dough cutting. The goal of the research was to develop an efficient and accurate dough notching system that would increase productivity and reduce the need for manual labour in bakeries.

The system consists of three main components: the robot UR5e for precise slicing, camera Visionary-T for capturing bread point clouds, and a conveyor belt for transporting the bread through the process. We also used a computer to process the point clouds, using the Python programming language.

The system components are connected to the laboratory network via an Ethernet connection and communicate via TCP/IP protocol. The Visionary-T camera is connected to the UR5e robot. When the laser on the conveyor belt detects the presence of dough, the belt stops, and the camera captures a point cloud, which is then sent to the computer via the FTP protocol.

The computer processes the point cloud using an algorithm that includes statistical outlier removal and plane removal using Random Sample Consensus (RANSAC). We manually determine the plane coefficients based on the setup of the Visionary-T camera. The point cloud is then smoothed and the axes are determined using Principal Component Analysis (PCA). At this point, the dimensions of the dough are also measured and the optimal square-shaped box for the bread dough is designed. Depending on the user's requirements, the cutting angle and the number of cuts are determined, with the user specifying how the bread dough should be cut. Each specified point contains three coordinates (x , y , z), which are sent to the robot after proper calibration, since the camera and robot use different coordinate systems. For the purpose of this research, we

have defined three cutting lines, which means 18 points ($3 \text{ lines} \times 2 \text{ points} \times 3 \text{ coordinates}$).

When the robot receives these points, the belt restarts, and the robot starts cutting the bread dough. The system allows the cutting mode to be adjusted via the computer, allowing various shapes and cutting patterns of the bread dough.

The research was conducted experimentally by integrating and optimising the performance of all components. The main findings include increased accuracy of bread dough notching, reduced waste and increased production speed. The system is adaptable to different types and sizes of bread dough, further enhancing its usefulness in bakeries. Based on the results, we concluded that the system is reliable and efficient for use in bakeries.

Key words: robotics, automation, UR5e, Visionary-T, conveyor belt, point cloud processing, calibration, automated dough notching.

Kazalo

1	Uvod	1
2	Robotski sistem za zarezovanje testa	3
2.1	Komponente robotskega sistema	3
2.1.1	Robotski manipulator UR5e	4
2.1.2	Prijemalo Hand-E	6
2.1.3	Senzor Visionary-T	6
2.1.4	Tekoči trak	7
2.1.5	Laserski senzor	7
2.2	Komunikacija	8
3	Prepoznavanje in lokalizacija testa	11
3.1	Odstranjevanje izstopajočih vrednosti iz oblaka točk	12
3.2	Zmanjšanje števila točk	15
3.3	Tehnike za odstranjevanje ravnin iz oblakov točk	18
3.4	Glajenje oblakov točk	21

4	Načrtovanje trajektorij zarezovanja	25
4.1	Ideja	25
4.2	Postopek zarezovanja	26
5	Eksperimentalna validacija	33
6	Zaključek	37
6.1	Možne izboljšave za prihodnosti	37
	Literatura	39

Seznam slik

1.1	Avtomatizirana linija za pripravo kruha.	1
2.1	Robot UR5e, Universal Robots.	4
2.2	Ročna učna enota.	5
2.3	Prijemalo Hand-E.	6
2.4	Senzor Visionary-T, SICK.	6
2.5	Tekoči trak.	7
2.6	Laserski senzor W16, SICK.	8
2.7	Komunikacija, shematski prikaz povezave komponent.	8
2.8	Sistem za zarezovanje testa.	9
3.1	Zajeti originalni oblaki točk a) testni oblak točk, b) dejansko testo na tekočem traku.	11
3.2	Omejen prostor v katerem se lahko nahaja a) objekt testnega oblaka točk, b) testo nad tekočim trakom.	12
3.3	Metoda SOR na a) testnem oblaku točk, b) oblaku točk krušnega testa.	15

3.4	Filtriranje mreže vokslov na a) testnem oblaku točk, b) oblaku točk krušnega testa.	17
3.5	Uporaba RANSAC na a) testnem oblaku točk, b) oblaku točk krušnega	19
3.6	Transformiran oblak točk a) testnega objekta, b) krušnega testa.	20
3.7	Rezultati sredinjskega filtra a) na testnem oblaku točk, b) oblaku točk krušnega testa.	23
4.1	PCA analiza a) testnega oblaka točk, b) oblaka točk krušnega testa.	27
4.2	Prilagojene osi a) modela po PCA analizi, b) krušnega testa po PCA analizi.	28
4.3	Dimenzije a) modela, določene s PCA analizo, b) krušnega testa, določene s PCA analizo.	28
4.4	Dizajnirana je škatla za a) objekt testnega oblaka točk in b) oblak točk krušnega testa.	29
4.5	Nastavitev parametrov za zarezovanje, kot $\alpha = 40^\circ$ in število zarezovanj = 3 a) objekt za testiranje, b) krušno testo.	30
4.6	a) model pripravljen za zarezovanje, b) krušno testo pripravljeno za zarezovanje.	31
5.1	Testni sistem za zarezovanje testa.	33
5.2	Potek zarezovanja, kot $\alpha = 0^\circ$ in število linij zarezovanja = 3.	35
5.3	Tri linije zarezovanja in kot a) $\alpha = 30^\circ$, b) $\alpha = 0^\circ$, c) $\alpha = 30^\circ$	36

1 Uvod

V sodobni dobi tehnološkega napredka avtomatizacija prevzema ključno vlogo v različnih industrijskih sektorjih, še posebej pa izstopa v prehrambeni industriji. Med procesi, ki so bili tradicionalno ročni, je priprava krušnega testa še posebej zanimiva, saj zahteva natančnost in ponovljivost, ki ju lahko robotizacija izboljša. Celoten proces avtomatizirane priprave kruha, od začetka do konca, je predstavljen na sliki 1.1.



Slika 1.1: Avtomatizirana linija za pripravo kruha.

Proces avtomatizirane priprave kruha se začne z natančnim doziranjem in mešanjem osnovnih sestavin, kot so moka, voda, kvas in sol. Po mešanju testo preide skozi avtomatizirano gnetenje, ki razvije gluten in omogoča, da testo vzhaja pod idealnimi pogoji temperature in vlažnosti. Ko je testo vzhajano, se razdeli in oblikuje v želene oblike. Pred peko se testo zareže, kar vpliva na končno teksturo in obliko kruha. Na koncu se kruh peče v pečeh z natančno nadzorovanimi temperaturami, kar zagotavlja visoko kakovost izdelkov.

Fokus naše diplomske naloge je usmerjen v avtomatizirano zarezovanje krušnega testa, ki predstavlja ključni korak v procesu oblikovanja in peke kruha. Ta operacija ima pomemben vpliv na estetski izgled, teksturo ter enakomerno razpokanje skorje kruha. Natančno izvedene zareze so bistvene za nadzor širjenja testa med peko, kar neposredno vpliva na kakovost končnega pekovskega izdelka.

Da bi dosegli zastavljeni cilj naše diplomske naloge, smo delo razdelili na več podciljev, ki sledijo logičnemu zaporedju. Prvi podcilj je razviti metodo za natančno zaznavanje krušnega testa, ki omogoča prepoznavanje različnih oblik in lastnosti testa. Ko je testo uspešno zaznano, bo sledil postopek zarezovanja, prilagojen specifikacijam zaznanega testa. Za to bomo uporabili ustrezno opremo, ki zagotavlja natančno in učinkovito izvedbo zarezov. Nato bomo integrirali vse komponente sistema, da zagotovimo nemoteno komunikacijo in usklajeno delovanje med različnimi deli sistema. Sledi še kalibracija robotskega sistema, ki bo zagotovila njegovo natančnost in zanesljivost pri izvajanju operacij. Na koncu bo sistem potrebno eksperimentalno validirati, da preverimo njegovo učinkovitost in zanesljivost v realnih proizvodnih pogojih.

2 Robotski sistem za zarezovanje testa

Robotski sistemi za zarezovanje testa predstavljajo pomemben napredek v pekarski industriji, saj omogočajo visoko natančnost, doslednost in učinkovitost pri pripravi testa za peko. Tradicionalni ročni postopki zarezovanja so pogosto časovno potratni in zahtevajo visoko raven spretnosti, kar lahko vodi do variabilnosti v kakovosti končnega izdelka. Nasprotno pa robotski sistemi zagotavljajo ponovljivost in zmanjšajo možnost človeških napak.

Ti sistemi običajno vključujejo napredne tehnologije, kot so visokoresolucijske kamere, senzorji in robotski manipulatorji, ki so programirani za izvajanje natančnih rezov. Uporaba teh tehnologij ne samo da izboljša estetiko zarezanega testa, ampak lahko vpliva tudi na teksturo in razporeditev sestavin v kruhu, kar je ključno za kakovost pekovskih izdelkov. Z napredkom tehnologije smo razvili lastni sistem za zarezovanje krušnega testa, ki združuje te inovacije za maksimalno natančnost in učinkovitost.

2.1 Komponente robotskega sistema

Pri razvoju našega robotskega sistema za rezanje kruha smo se osredotočili na integracijo različnih tehnološko naprednih komponent, ki skupaj tvorijo učinkovito in natančno delujoč sistem. Vsaka komponenta ima specifično vlogo in je ključna za uspešno delovanje celotnega sistema. Razumevanje funkcij in medsebojnega delovanja teh komponent je temelj za dojetje, kako naš sistem zagotavlja dosledno visoko kakovost rezanja. V nadaljevanju so podrobneje predstavljene glavne komponente našega sistema, vključno s kamero Visionary-T, robotskim manipulatorjem UR5e, tekočim trakom in laserskim senzorjem.

2.1.1 Robotski manipulator UR5e

Robotski manipulator UR5e [1], priljubljen sodelujoči robot (ang. *collaborative robot* - *cobot*), je izdelek danskega podjetja Universal Robots. Je ključna komponenta našega sistema za avtomatizirano zarezovanje testa. Znan je po svoji prilagodljivosti, enostavnosti uporabe in visoki natančnosti, kar ga naredi idealnega za delo v pekarski industriji. Robotski manipulator UR5e je prikazan na sliki 2.1.



Slika 2.1: Robot UR5e, Universal Robots.

1. Tehnične specifikacije

Masa 18,4 kg omogoča enostaven transport in namestitvev. Doseg robota je 850 mm, kar zagotavlja ustrezno operativno območje. Nosilnost do 5 kg je primerna za manipulacijo z različnimi orodji in obremenitvami. Ponovljivost znaša $\pm 0,03$ mm, kar zagotavlja natančnost pri ponavljajočih se operacijah.

2. Programiranje in prilagodljivost

UR5e izstopa z intuitivnim grafičnim uporabniškim vmesnikom, ki omogoča enostavno programiranje neposredno na robotu ali prek oddaljenega dostopa. Ta zmožnost olajša prilagajanje in optimizacijo procesov brez obsežnega tehničnega znanja.

3. Varnostne funkcije

Kot sodelujoči robot, UR5e zagotavlja varno delovanje v neposredni bližini operaterjev, brez potrebe po dodatnih varnostnih sistemih. Robot vključuje napredne senzorske tehnologije, ki zaznavajo prisotnost ljudi in prilagajajo operacije, s čimer preprečuje poškodbe ali nesreče.

4. Vzdrževanje in trajnost

UR5e je zasnovan za dolgotrajno delovanje z minimalnim vzdrževanjem, kar zmanjšuje skupne obratovalne stroške in podaljšuje življenjsko dobo naprave.




Slika 2.2: Ročna učna enota.

Ročna učna enota omogoča učinkovito programiranje in nadzor robotskega manipulatorja UR5e. Je kompaktna in lahka, z barvnim zaslonom na dotik za lažjo interakcijo in vizualno podporo. Vključuje gumb za zaustavitev v sili, ki omogoča takojšnje ustavljanje robota v nevarnih situacijah, kar izboljšuje varnost delovnega okolja. USB povezljivost olajša prenos programov in podatkov, Polyscope vmesnik pa zagotavlja intuitivno uporabniško izkušnjo.

2.1.2 Prijemalo Hand-E

Prijemalo tipa Hand-E je zasnovano za natančno in zanesljivo rokovanje z orodji, kot je nož za zarezovanje testa. Zahvaljujoč svoji prilagodljivosti in robustnosti, prijemalo omogoča manipulatorju UR5e, da izvaja kompleksne naloge z visoko stopnjo natančnosti. To je še posebej pomembno pri aplikacijah, kot je zarezovanje krušnega testa, kjer je ključna doslednost in preciznost rezov.



Slika 2.3: Prijemalo Hand-E.

2.1.3 Senzor Visionary-T

Senzor Visionary-T, proizvod podjetja SICK, je globinski senzor, ki deluje na principu merjenja časa preleta (ang. *Time-of-Flight, ToF*). Ta tehnologija omogoča zbiranje tridimenzionalnih podatkov. V našem sistemu za zarezovanje testa ima ključno vlogo, saj zagotavlja določitev lege testa, kar je bistveno za doseganje optimalnih rezov. Senzor Visionary-T, je predstavljen na sliki 2.4.



Slika 2.4: Senzor Visionary-T, SICK.

1. Tehnične specifikacije

Senzor Visionary-T ima ločljivost 176×144 pikslov, zajema do 50 slik na sekundo, z merilnim dometom od 0,5 do 60 metrov. Hitrostjo prenosa podatkov je do 60 Mbit/s preko Gigabit Ethernet vmesnika. Razred zaščite je IP67.


2. Uporaba in prilagodljivost

Programska podpora vključuje GenICam (Halcon), Point Cloud Library (PCL), Java in druge vmesnike, kar omogoča hitro integracijo v različne sisteme. Prilagodljivost senzorja se kaže v različnih načinih delovanja, ki omogočajo sočasno uporabo več senzorjev brez medsebojnega vplivanja.

Senzor Visionary-T, čeprav uporaben za mnoge aplikacije, ima nižjo ločljivost v primerjavi z nekaterimi drugimi industrijskimi senzorji, kar ga lahko omejuje pri uporabi v natančnih aplikacijah, kjer so zahtevani fini detajli.

2.1.4 Tekoči trak

Tekoči trak [2] ima v našem sistemu za zarezovanje krušnega testa ključno vlogo pri zagotavljanju nemotenega in enakomernega prenosa testa skozi celotni proces zarezovanja. Omogoča enakomerno in natančno gibanje testa pod robotskim manipulatorjem, kar je bistveno za dosledno kakovost rezov. Vizualni prikaz tekočega traku si lahko ogledamo na sliki 2.5.



Slika 2.5: Tekoči trak.

2.1.5 Laserski senzor

Laserski senzor [3] iz družine W16, podjetja SICK, je namenjen zanesljivemu zaznavanju objektov z uporabo fotoelektrične tehnologije. Senzor uporablja teh-

nologijo odboja svetlobe (ang. *retro-reflective*) in je opremljen s funkcijo samodejnega prilagajanja in BluePilot za lažje usmerjanje. Z robustno zasnovo, odporno na kemikalije, toploto in mehanske vplive, senzor zagotavlja visoko zanesljivost za industrijske aplikacije. Senzor je ključen za natančno zaznavanje testa v našem sistemu, kar omogoča zmanjšanje zastojev v proizvodnji. Izgled in dizajn laserskega senzorja si lahko ogledamo na sliki 2.6.


Senzor uporablja PinPoint LED za natančno zaznavanje, z dometom zaznavanja od 10 mm do 500 mm, medtem ko zaščita razreda IP67 zagotavlja delovanje v zahtevnih okoljih.



Slika 2.6: Laserski senzor W16, SICK.

2.2 Komunikacija

V laboratoriju za robotiko smo v okviru našega sistema uspešno zasnovali in sestavili inovativen robotski sistem za zarezovanje testa. Komponente sistema so medsebojno integrirane, kar zagotavlja njegovo učinkovito delovanje. Na sliki 2.7 je ta integracija prikazana, kjer so vse komponente združene v enoten, funkcionalen sistem.



Slika 2.7: Komunikacija, shematski prikaz povezave komponent.


Komunikacija in povezava komponent v robotskem sistemu za zarezovanje testa sta ključnega pomena za njegovo natančno in učinkovito delovanje. Senzor Visionary-T je neposredno povezan s krmilnikom robota UR5e prek digitalnega I/O vmesnika, kar omogoča, da senzor prejme signal za zajem oblaka točk. Ko

senzor Visionary-T zazna pozitivno fronto signala, se oblak točk samodejno shrani v njegov pomnilnik. Senzor je povezan z računalnikom in preko FTP protokola [4] pošilja zajete oblake točk na računalnik. Robot je povezan z računalnikom prek laboratorijskega omrežja z Ethernet povezavo [5], kar omogoča komunikacijo med njima prek TCP/IP protokola [6].

Poleg tega je robot UR5e prek digitalnega I/O vmesnika povezan tudi s tekočim trakom in laserskimi senzorji, kar omogoča usklajeno delovanje celotnega sistema. Proces se začne s postavitvijo krušnega testa na tekoči trak, ki se nato zažene. Ko laserski senzor zazna prisotnost testa, robot zaustavi trak in sproži signal za zajem oblaka točk s senzorjem Visionary-T. Hkrati robot obvesti računalnik, da je oblak točk zajet, ter zahteva shranjevanje oblaka točk iz senzorja v računalnikov pomnilnik.

Nato računalnik, na podlagi uporabnikovih zahtev, kot sta število rezov in kot rezanja, izračuna optimalno trajektorijo zarezovanja. V našem primeru smo izbrali 3 linije zarezovanja. Glede na to računalnik pošlje robotu 18 kalibriranih točk [7] (3 linije $\times$ 2 točki $\times$ 3 koordinate). Ko robot prejme te točke, se tekoči trak ponovno zažene, robot pa začne z zarezovanjem testa, pri čemer se prilagodi hitrosti traku. Po končanem zarezovanju se robot vrne v začetni položaj, medtem ko drugi laserski senzor zazna prisotnost testa in ustavi trak.


Ko je zarezovanje zaključeno, je krušno testo pripravljeno, da se pošlje v pečico. S tem postopkom smo preprečili, da bi kruh med peko počil, kar zagotavlja visoko kakovost končnega izdelka. Celoten sistem je prikazana na sliki 2.8.



Slika 2.8: Sistem za zarezovanje testa.

3 Prepoznavanje in lokalizacija testa


Prepoznavanje in lokalizacija testa v tridimenzionalnem prostoru sta ključna za natančno avtomatizirano zarezovanje krušnega testa. Prepoznavanje testa se začne z zajemom podatkov s kamero Visionary-T, ki pridobi tridimenzionalne oblake točk, sestavljene iz podatkov o površini in obliki testa. Rezultate prvotnih oblakov točk, zajetih s kamero Visionary-T, si lahko ogledamo na sliki 3.1.



Slika 3.1: Zajeti originalni oblaki točk a) testni oblak točk, b) dejansko testo na tekočem traku.

Posebno pozornost posvečamo omejevanju komponent x , y in z oblaka točk glede na definiran prostor. To vključuje odstranitev vseh točk, ki se nahajajo izven prostora, definiranega s šestimi ravninami (kvadra), kar omogoča bolj osredotočeno analizo območja zanimanja.

Ta postopek zagotavlja, da se analiza izvaja le na relevantnih podatkih za območje, kjer se lahko nahaja testo. Primer je prikazan na sliki 3.2.



Slika 3.2: Omejen prostor v katerem se lahko nahaja a) objekt testnega oblaka točk, b) testo nad tekočim trakom.

Za zagotovitev natančnosti in zanesljivosti pridobljenih podatkov izvedemo večstopenjsko obdelavo oblaka točk, vključno z odstranjevanjem izstopajočih točk, zmanjševanjem števila točk za boljšo računsko učinkovitost, odstranjevanjem nepotrebnih ozadij in glajenjem površin za izboljšanje kakovosti podatkov. V nadaljevanju so podrobno opisani algoritmi, ki se uporabljajo za te korake.

3.1 Odstranjevanje izstopajočih vrednosti iz oblaka točk

Odstranjevanje odstopanj je ključni korak pri obdelavi podatkov, ki pogosto vsebujejo šum in anomalije. Te izstopajoče vrednosti lahko popačijo analizo in negativno vplivajo na aplikacije, kot sta 3D modeliranje in zaznavanje predmetov. Za reševanje tega problema so bili razviti različni filtri in tehnike za učinkovito prepoznavanje in odpravljanje različnih vrst odstopanj.

Metode segajo od statističnih pristopov do tehnik, ki temeljijo na grozdenju, pri čemer je vsaka prilagojena specifičnim značilnostim odstopanj. Oglejmo si najbolj znane metode:

1. Statistično odstranjevanje odstopanj (ang. *Statistical Outlier Removal, SOR*) [8]

SOR metoda izračuna srednjo vrednost in standardni odklon razdalj do najbližjih sosedov vsake točke. Točke, ki znatno odstopajo od tega povprečja, se štejejo za obrobne in se odstranijo. Metoda je učinkovita za zmanjševanje šuma, vendar je občutljiva na nastavitve parametrov.

Lokalno statistično odstranjevanje odstopanj (ang. *Local Statistical Outlier Removal, LSOR*) je različica standardne metode SOR, ki se osredotoča na lokalne lastnosti oblaka točk. Namesto analize oblaka točk kot celote, lokalni SOR upošteva lokalne gostote točk.

2. Odstranjevanje izstopajočih točk z radijem (ang. *Radius Outlier Removal*) [9]

Odstranijo se točke, ki imajo v danem polmeru manj sosedov od določenega praga. To je namenjeno točkam, ki so prostorsko izolirane, s čimer se učinkovito očistijo redki podatki.

3. Gostotno odvisno prostorsko združevanje aplikacij s šumom (ang. *Density-Based Spatial Clustering of Applications with Noise, DBSCAN*) [10]

DBSCAN, je predvsem metoda grozdenja, pomaga pa tudi pri prepoznavanju izstopajočih točk, ki ne spadajo v noben grozd. Uporabna je za podatkovne nize z različno gostoto.

4. Grozdenje s srednjim premikom (ang. *Mean Shift Clustering*) [11]

Tehnika grozdenja pomaga prepoznati goste regije s premikanjem proti centroidom, pri čemer izloči izstopajoče točke, ki ne pripadajo nobeni gosti regiji.

5. Filtriranje z obrezanim povprečjem (ang. *Trimmed Mean Filtering*) [12]

Metoda vključuje odstranjevanje fiksne odstotka skrajnih podatkovnih točk, preden se izračuna povprečje, kar pomaga zmanjšati vpliv ekstremnih vrednosti.


6. Robustna analiza glavnih komponent (ang. *Robust Principal Component Analysis, RPCA*) [13]

RPCA razgradi podatke na nizko rangirane in redke komponente, pri čemer redki del zajame izstopajoče vrednosti, ki jih je nato mogoče zavreči.

7. Filtriranje na podlagi Mahalanobisove razdalje (ang. *Mahalanobis Distance-based Filtering*) [14]

To statistično merilo pomaga prepoznati izstopajoče vrednosti z izračunom razdalje vsake točke od povprečja podatkovnega niza, pri čemer se upošteva kovarianca med dimenzijami podatkov.

Za odstranjevanje odstopanj iz oblaka točk smo izbrali statistično metodo odstranjevanje odstopanj zaradi njene enostavnosti, učinkovitosti in prilagodljivosti. Metoda SOR temelji na enostavni statistični analizi razdalj med točkami in njihovimi najbližjimi sosedi, kar omogoča hitro in učinkovito odstranjevanje odstopanj. Ta metoda je še posebej učinkovita za podatke z normalno porazdelitvijo, saj zagotavlja zanesljive rezultate brez potrebe po kompleksnem nastavljanju parametrov. Poleg tega je SOR metoda manj občutljiva na izbiro parametrov v primerjavi z drugimi metodami, kot je DBSCAN, kar poenostavi njeno uporabo in prilagoditev specifičnim značilnostim podatkovnega nabora. Rezultati uporabe metode SOR so prikazani na sliki 3.3.



Slika 3.3: Metoda SOR na a) testnem oblaku točk, b) oblaku točk krušnega testa.

3.2 Zmanjšanje števila točk

Pri obdelavi 3D podatkov so tehnike za zmanjšanje števila točk ključne za upravljanje velikih oblakov točk, saj zmanjšujejo njihovo velikost in hkrati ohranjajo pomembne geometrijske podrobnosti. Te tehnike segajo od preprostega naključnega vzorčenja do bolj kompleksnih metod, kot je vzorčenje na podlagi ukrivljenosti, in so primerne za različne potrebe obdelave. V tem pregledu predstavljamo različne metode oziroma filtre za zmanjšanje števila točk ter poudarjamo njihove pristope in uporabo pri učinkovitem poenostavljanju podatkov oblakov točk. V nadelevanju so opisani nekateri najpogostejše uporabljeni filtri:

1. Filtriranje mreže vokslov (ang. *Voxel Grid Filtering*) [15]

Filter razdeli oblak točk na mrežo prostorninskih celic (vokslov) in poenostavi podatke tako, da iz vsakega voksla ohrani le reprezentativno točko, pogosto centroid. To znatno zmanjša število točk in računsko obremenitev, hkrati pa ohranja splošno obliko.

2. Progresivne mreže (ang. *Progressive Meshes*) [16]

Tehnika zmanjšuje število vrhov v mreži z zaporednim združevanjem, kar minimalno vpliva na splošno obliko. Primarno se uporablja za poenostavitve mrež, vendar se lahko prilagodi tudi za oblake točk, da ohrani visoko raven podrobnosti na kritičnih območjih.

3. Vzorčenje najbolj oddaljene točke (ang. *Farthest Point Sampling, FPS*) [17]

Točke so izbrane na podlagi največje razdalje od vseh že izbranih točk, kar zagotavlja, da vsaka nova točka doda edinstvene prostorske informacije. Posebej učinkovita je pri ohranjanju pomembnih geometrijskih lastnosti za aplikacije, kot sta 3D modeliranje in strojno učenje.

4. Vzorčenje z oktarnim drevesom (ang. *Octree Sampling*) [18]

Pristop uporablja drevesno podatkovno strukturo za rekurzivno razdelitev 3D prostora na manjše osmerokotnike. Točke je mogoče vzorčiti ali zmanjšati na različnih ravneh te hierarhije, kar omogoča podroben nadzor nad ločljivostjo in gostoto končnega oblaka točk.

5. Naključno vzorčenje (ang. *Random Sampling*) [19]

Naključno vzorčenje je enostavna tehnika, pri kateri se iz prvotnega oblaka točk naključno izbere podmnožica točk. Filter je hiter in enostaven za izvedbo, vendar morda ne ohranja geometrijskih podrobnosti tako učinkovito kot drugi filtri.

6. Enotno podvzorčenje (ang. *Uniform Subsampling*) [20]


Točke so izbrane po pravilnem vzorcu ali razmiku, kar zagotavlja enakomerno porazdelitev po oblaku točk. Filter ohranja enakomerno gostoto podatkov, kar je ključno za nekatere analitične aplikacije.

7. Vzorčenje na podlagi ukrivljenosti (ang. *Curvature-based Sampling*) [21]

Točke so izbrane glede na ukrivljenost površine, ki jo predstavljajo. Območja z večjo ukrivljenostjo (več geometrijskih podrobnosti) ohranijo

več točk, medtem ko se ravna območja lahko zmanjšajo bolj agresivno. Ta filter je idealen za ohranjanje podrobnih geometrijskih značilnosti in povečuje hitrost obdelave.

Izbrali smo metodo filtriranja mreže vokslov, ker je enostavna za implementacijo in učinkovito zmanjšuje število točk v oblaku točk, kar bistveno povečuje hitrost obdelave podatkov. Metoda deli oblak točk na mrežo prostorninskih celic (vokslov) in poenostavi podatke tako, da ohrani le reprezentativno točko iz vsakega voksla, pogosto centroid. V primerjavi z bolj zapletenimi metodami, kot je vzorčenje na podlagi ukrivljenosti, je filtriranje z mrežo vokslov računsko manj zahtevno in hitrejše za izvedbo. Čeprav morda ne ohranja tako natančno podrobnosti na ukrivljenih površinah, je ta filter zelo primeren za aplikacije, kjer je pomembno hitro in enostavno zmanjšanje velikosti podatkov, kot so površinske značilnosti krušnega testa. Pri zarezovanju testa ni potrebe po vseh podrobnostih, ki jih pridobimo iz oblaka točk, zato je ta metoda še posebej uporabna. S svojo enostavnostjo in učinkovitostjo je filtriranje z mrežo vokslov zanesljiva izbira za obdelavo velikih oblakov točk. Rezultati te metode so prikazani na sliki 3.4.



Slika 3.4: Filtriranje mreže vokslov na a) testnem oblaku točk, b) oblaku točk krušnega testa.

3.3 Tehnike za odstranjevanje ravnin iz oblakov točk

Odstranjevanje ravnine, na kateri leži objekt, je ključni korak pri izolaciji objekta od ozadja in izboljšanju natančnosti nadaljnjih analiz v obdelavi oblakov točk. Ta postopek omogoča pridobivanje bolj uporabnih podatkov za različne aplikacije, kot sta analiza oblik in strojno učenje. Obstaja več tehnik za odstranjevanje ravnin iz oblakov točk, vsaka s svojim specifičnim pristopom in uporabo. V nadaljevanju so opisane nekatere pogosto uporabljene tehnike za odstranjevanje ravnin:

1. RANSAC prileganje ravnine (ang. *RANSAC(Random Sample Consensus) Plane Fitting*) [22]

RANSAC je zanesljiva in prilagodljiva metoda za prilagajanje ravnine oblaku točk. Deluje z iterativnim izbiranjem naključnih podmnožic točk in izračunom najboljše prilegajoče se ravnine. Točke, ki se ne prilegajo ravnini v okviru določenega odstopanja, se štejejo za izstopajoče in se odstranijo. Tehnika je učinkovita pri obravnavi šumnih podatkov in lahko obravnava velik delež izstopajočih vrednosti.

2. Houghova transformacija (ang. *Hough Transform*) [23]

Houghova transformacija je tehnika za ekstrakcijo značilnosti, ki se uporablja za zaznavanje geometrijskih oblik. V okviru odstranjevanja ravnin lahko prepozna in odstrani ravnine s preoblikovanjem podatkov oblaka točk v prostor parametrov, kjer so ravnine predstavljene kot točke. Ta metoda je še posebej učinkovita za zaznavanje več ravnin v kompleksnih prizorih.

3. Segmentacija z rastočo regijo (ang. *Region Growing Segmentation*) [24]

Tehnika se začne z začetno semensko točko in širi regijo z dodajanjem sosednjih točk, ki izpolnjujejo določene kriterije, kot sta podobnost površinskih normal in prag razdalje. Ko je regija ravnine identificirana, jo je mogoče odstraniti iz oblaka točk. Segmentacija z rastjo regij je uporabna za prepoznavanje in odstranjevanje lokaliziranih ravninskih površin.


4. Odštevanje ravnin s pomočjo normale površine (ang. *Plane Subtraction Using Surface Normals*) [25]

Metoda z izračunavanjem površinskih normal točk v oblaku identificira in odstrani točke, ki pripadajo ravninski površini. Temelji na doslednosti površinskih normal čez ravnino in je učinkovita za ravne, dobro definirane površine.

5. Odstranjevanje ravnine z mrežo vokslov (ang. *Voxel Grid Plane Removal*) [26]


Tehnika zmanjša število točk z uporabo filtriranja mreže vokslov, nato pa iz zmanjšanega oblaka točk identificira in odstrani voksle, ki ležijo na ravnini. To je enostavna metoda, ki temelji na začetnem zmanjšanju mreže vokslov.

Zaradi robustnosti in učinkovitosti pri obravnavanju šumnih podatkov in velikega deleža izstopajočih vrednosti smo za prilagajanje ravnine izbrali metodo RANSAC. V primerjavi z drugimi metodami, kot sta Houghova transformacija in segmentacija z rastjo regij, RANSAC omogoča iterativno izbiro naključnih podmnožic točk in izračunavanje najbolj prilagajoče se ravnine, kar zagotavlja zanesljive rezultate tudi v prisotnosti znatnega šuma. Poleg tega je metoda manj občutljiva na predhodne domneve o podatkih, kar jo naredi bolj prilagodljivo in vsestransko uporabno v različnih scenarijih. Zaradi teh prednosti je bil RANSAC idealna izbira za odstranjevanje ravnin in izboljšanje natančnosti nadaljnjih analiz oblakov točk. Primera uporabe te metode sta prikazana na sliki 3.5.



Slika 3.5: Uporaba RANSAC na a) testnem oblaku točk, b) oblaku točk krušnega

Po odstranjevanju ravnine je naslednji izziv, s katerim se soočamo, transformacija oblaka točk na način, ki omogoča lažje pridobivanje informacij o testu oziroma modelu, kot so višina, širina in dolžina objekta. Ta postopek smo izvedeli s pomočjo algoritma RANSAC, iz katerega smo pridobili koeficiente ravnine, prek katerih smo določili realne višine objekta. Ker kamera praktično nikoli ni pravokotna na ravnino, na kateri leži objekt (testo), lahko pride do nepravilno orientiranih podatkov. Zato transformacija oblaka točk vključuje poravnavo in orientacijo točk v standardni koordinatni sistem, kar omogoča enostavnejšo analizo in vizualizacijo. Poleg tega, ker kamera zagotavlja podatke v milimetrih, lahko osnovne podatke neposredno preberemo v milimetrih, kar olajša natančno merjenje dimenzij objekta. Tako postane obdelava in analiza podatkov hitrejša in bolj zanesljiva. Rezultate si lahko ogledamo na sliki 3.6.



Slika 3.6: Transformiran oblak točk a) testnega objekta, b) krušnega testa.

3.4 Glajenje oblakov točk

Glajenje oblakov točk je ključen korak pri obdelavi tridimenzionalnih podatkov, saj omogoča zmanjšanje šuma in izboljšanje kakovosti zajetih podatkov. Pri zajemanju oblakov točk s senzorji, kot so 3D kamere ali laserski skenerji, se pogosto pojavijo nepravilnosti in šum, ki izvirajo iz različnih virov, vključno z omejitvami strojne opreme, pogoji okolja ali samim procesom zajemanja podatkov. Cilj glajenja je zmanjšati te nepravilnosti in ustvariti bolj gladko ter reprezentativno površino oblakov točk, kar prispeva k boljši natančnosti in zanesljivosti nadaljnje analize, vizualizacije ali izdelave modelov. Glajenje omogoča tudi boljšo interpretacijo podatkov, saj odstranjuje naključne variacije, ki lahko motijo prepoznavanje in obdelavo pomembnih značilnosti. Obstajajo različne metode in tehnike za glajenje oblakov točk, ki se lahko prilagodijo specifičnim potrebam in značilnostim podatkov. Vsaka metoda ima svoje prednosti in slabosti, odvisno od vrste podatkov in zahtev končnega uporabnika. V nadaljevanju so opisane nekatere najbolj znane tehnike za glajenje oblakov točk:

1. Premikanje najmanjših kvadratov (ang. *Moving Least Squares, MLS*) [27]

Metoda prilagaja lokalne okolice točk polinomom višjega reda. Z ocenjevanjem povprečnih površin znotraj teh sosedstev MLS zgladi in ponovno vzorči šumne podatke. Učinkovito zmanjšuje majhne merilne napake ter zagotavlja natančno oceno normal površin. Metoda je še posebej uporabna za ohranjanje celovitosti prvotne površine ob odstranjevanju šuma.

2. Glajenje na podlagi difuzije (ang. *Diffusion-Based Smoothing*) [28]

Difuzijske metode uporabljajo koncept toplotne difuzije za glajenje oblaka točk. Točke se iterativno prilagajajo glede na povprečni položaj njihovih sosedov, kar vodi k postopnemu zmanjševanju šuma. Metoda je učinkovita pri enakomernem zmanjševanju šuma po celotnem oblaku točk, medtem ko ohranja celotno obliko in strukturo.

3. Glajenje na podlagi vidnosti (ang. *Saliency-Guided Smoothing*) [29]

Metoda prilagodi postopek glajenja glede na izpostavljenost (ang. *saliency*) točk. Osredotoča se na ohranjanje ključnih geometrijskih značilnosti površine, kot so ostri robovi, robovi oblik in drugi pomembni detajli, medtem ko zmanjšuje šum. Pristop zagotavlja, da se pomembne podrobnosti površine ohranijo, medtem ko se zmanjšuje deformacija, ki lahko nastane pri bolj agresivnih tehnikah glajenja.

4. Bilateralni filter (ang. *Bilateral Filter*) [30]

Bilateralno filtriranje zgladi podatke in hkrati ohrani robove. Združuje domensko filtriranje in filtriranje po obsegu, kar pomeni, da upošteva tako prostorsko bližino kot razliko v intenzivnosti med točkami, s čimer se izogne zameglitvi robov. Metoda je učinkovita pri ohranjanju ostrih lastnosti ob hkratnem zmanjševanju šuma.

5. Gaussov filter (ang. *Gaussian Filter*) [31]

Gaussov filter uporablja Gaussovo funkcijo za glajenje oblaka točk. Točkam dodeli uteži glede na njihovo razdaljo od ciljne točke, pri čemer imajo bližje točke večji vpliv. Metoda je preprosta in učinkovita za zmanjševanje Gaussovega šuma, vendar lahko zamegli ostre robove.


6. Sredinjski filter (ang. *Median Filter*) [32]

Sredinjski filter deluje tako, da vsako točko nadomesti z mediano točk v njenem lokalnem sosedstvu. Metoda je še posebej učinkovita pri odstranjevanju izstopajočih vrednosti, pri čemer ohranja robove bolje kot Gaussov filter.

7. Glajenje z upoštevanjem robov (ang. *Edge-Aware Smoothing*) [33]

Tehnike glajenja z upoštevanjem robov uporabljajo informacije o robovih v oblaku točk za uporabo različnih stopenj glajenja na različnih območjih. To pomaga ohranяти robove, medtem ko se zgladi preostala površina, kar ohranja pomembne geometrijske lastnosti.

Za potrebe našega dela smo izbrali sredinjski filter zaradi njegove sposobnosti izboljšanja kakovosti oblakov točk, hkrati pa ohranja ključne strukturne lastnosti podatkov. Sredinjski filter je še posebej primeren za obdelavo podatkov, kjer je pomembno ohranjanje geometrijske natančnosti, kot pri analizi testa za kruh. Za razliko od drugih filtrov, kot je Gaussov, ki lahko zamegli pomembne detajle, in bilateralnega filtra, ki zahteva natančno nastavitve parametrov, sredinjski filter zagotavlja optimalno ravnovesje med zmanjševanjem šuma in ohranjanjem natančnih oblik, kar je bil ključni razlog za njegovo izbiro v našem delu. Učinkovitost tega filtra in njegov vpliv na kakovost podatkov si lahko ogledamo na sliki 3.7.



Slika 3.7: Rezultati sredinjskega filtra a) na testnem oblaku točk, b) oblaku točk krušnega testa.

4 Načrtovanje trajektorij zarezovanja

Po uspešnem filtriranju oblaka točk, ki vsebuje informacije o krušnem testu, je naslednji cilj načrtovanje trajektorij zarezovanja in natančno zarezovanje. Da bi rešili to problematiko, smo se soočili s ključnimi vprašanji. Kako naj zarezujemo kruh, ki je predstavljen z oblakom točk? Kako naj to programiramo? Kako naj izvedemo rezanje, če se oblika krušnega testa lahko spremeni? Kako naj prilagodimo rezalni proces tem spremembam? Ali je možno spreminjati število zarezovanj? Ali je možno spreminjati način zarezovanja? Kako to izvedemo optimalno? Odgovori na ta vprašanja so bili ključni za razvoj našega dela, ki ne predstavlja le tehničnega izziva, temveč tudi priložnost za inovacije v načinu, kako pristopamo k pripravi in obdelavi pekovskih izdelkov.

4.1 Ideja

Ideja za reševanje problema zarezovanja testa, predstavljenega kot oblak točk, temelji na natančni identifikaciji lokalnih osi (osi oblaka točk). Glede na to, da se lahko oblika oblaka točk spremeni, smo izbrali strategijo, da zarezovanje vedno poteka vzdolž najdaljše lokalne osi, ki smo jo poimenovali lokalna os x . Poleg tega smo vzporedno z globalno osjo z določili lokalno os z . Preostalo os smo poimenovali y . Implementirali smo možnost, da uporabnik nastavi kot med lokalno komponento y in trajektorijo zarezovanja ter število zarez. Ta pristop omogoča natančno prilagoditev postopka glede na specifične zahteve in je ključen za optimizacijo procesa rezanja glede na trenutno obliko in velikost testa.

4.2 Postopek zarezovanja

V tem poglavju bomo podrobno obravnavali, kako smo izvedli identifikacijo osi v oblaku točk in kako te ugotovitve vplivajo na načrtovanje in izvedbo zarezovanja. Identifikacija osi je ključnega pomena za načrtovanje učinkovitih in prilagodljivih trajektorij zarezovanja. Te osi lahko razkrijejo notranjo strukturo podatkov in so bistvene za naloge, kot so prepoznavanje objektov, poravnavo in odkrivanje simetrije. Čeprav je na voljo več tehnik, so nekatere postale bolj razširjene zaradi svoje učinkovitosti in enostavne uporabe. V nadaljevanju so predstavljene najpogostejše uporabljene metode:

1. Analiza glavnih komponent (ang. *Principal Component Analysis, PCA*) [34]

PCA je statistični postopek, ki uporablja ortogonalno transformacijo za pretvorbo niza opazovanj morebitnih koreliranih spremenljivk v niz vrednosti linearno nekoreliranih spremenljivk, imenovanih glavne komponente. Metoda je še posebej priljubljena zaradi svoje sposobnosti identificiranja glavnih osi, ki zajemajo največjo varianco v podatkih oblaka točk.


2. Dekompozicija singularnih vrednosti (ang. *Singular Value Decomposition, SVD*) [35]

SVD je matematična metoda, ki razgradi matriko na njene singularne komponente. V kontekstu oblakov točk se SVD uporablja za iskanje osi podatkov, kar je lahko koristno za razumevanje njihovih geometrijskih lastnosti. Gre za robustno tehniko, ki se pogosto uporablja v natančnih inženirskih in znanstvenih študijah.

3. Razgradnja lastnih vrednosti kovariančne matrike (ang. *Eigenvalue Decomposition of the Covariance Matrix*) [36]

Tehnika vključuje razgradnjo kovariančne matrike oblaka točk na njene lastne vrednosti in lastne vektorje. Lastni vektorji predstavljajo osi oblaka, lastne vrednosti pa kažejo količino variance, ki jo nosi vsaka os. To je temeljno analitično orodje pri številnih statističnih nalogah, ki vključujejo večdimenzionalne podatke.


Izbrali smo metodo analize glavnih komponent (PCA) zaradi njene enostavnosti, učinkovitosti in statistične robustnosti. PCA nam omogoča temeljito analizo razpršenosti podatkov in jasno identifikacijo ključnih vzorcev variabilnosti v našem točkovnem oblaku. V primerjavi z drugimi tehnikami, kot je dekompozicija singularnih vrednosti (SVD), PCA izstopa zaradi svoje hitrosti in manjše občutljivosti na šum, kar je ključnega pomena pri obdelavi obsežnih podatkovnih naborov. Metoda združuje enostavnost, hitrost in prilagodljivost, kar jo naredi izjemno učinkovito za uporabo v različnih scenarijih. Konkretno rezultate učinkovitosti PCA si lahko ogledamo na sliki 4.1, kjer so osi sorazmerno narisane.



Slika 4.1: PCA analiza a) testnega oblaka točk, b) oblaka točk krušnega testa.


Po uporabi PCA analize lahko tako vizualno kot matematično ugotovimo, da lokalna os z' ni vzporedna z globalno osjo z . Medtem ko lokalni os x' in os y' sekata ravnino, opisano z enačbo $x + z + y = 0$, na kateri stoji naš objekt, česar si seveda ne želimo. To lahko vizualno ugotovimo iz slike 4.1.

Glede na naše zahteve moramo spremeniti osi. To storimo tako, da lokalno os z' nastavimo v nasprotno smer od naše globalne osi z , kar nam omogoča boljšo uskladitev z referenčnimi sistemskimi parametri. Nato ustvarimo novo lokalno os y' s pomočjo vektorskega produkta med novo osjo z' in že obstoječo osjo x' . Ko dobimo novo os y' , izvedemo še en vektorski produkt med osjo y' in osjo z' , s čimer dobimo novo os x' . Zadnji korak je normalizacija teh vektorjev, s čimer dobimo enotske vektorje, ki predstavljajo lokalne osi objekta. Rezultate tega procesa si lahko ogledamo na sliki 4.2.



Slika 4.2: Prilagojene osi a) modela po PCA analizi, b) krušnega testa po PCA analizi.


Analiza glavnih komponent (PCA) predstavlja ključno orodje ne le za identifikacijo glavnih osi v točkovnih oblakih, temveč ima tudi bistveno vlogo pri določanju maksimalnih dimenzij krušnih izdelkov v lokalnem koordinatnem sistemu. Ta metoda nam omogoča izluščenje glavnih komponent iz podatkov, ki predstavljajo smeri z največjo variabilnostjo. To nam ne omogoča le razumevanja oblike in orientacije krušnega testa, temveč nam tudi omogoča natančno merjenje njegovih dimenzij, kar je ključno za optimizacijo procesov zarezovanja. Rezultate določanja maksimalnih dimenzij kruha si lahko ogledamo na sliki 4.3, ki podrobno prikazuje, kako PCA analiza razkriva prostorske značilnosti testa, kar omogoča bolj učinkovito načrtovanje in izvajanje zarezovalnih postopkov.



Slika 4.3: Dimenzije a) modela, določene s PCA analizo, b) krušnega testa, določene s PCA analizo.

Ta podrobna analiza je še posebej pomembna v pekarstvu, kjer natančnost zarezovanja vpliva na kakovost končnih izdelkov in njihovo tržno privlačnost. Pravilna uporaba PCA lahko tako vodi do znatnih izboljšav v proizvodnih linijah in seveda zmanjšuje odpad.

V procesu naše raziskave smo že uspešno izračunali lokalne osi in maksimalne dimenzije kruha z uporabo analize glavnih komponent (PCA). Na podlagi teh natančno določenih parametrov smo pristopili k naslednjemu koraku, ki vključuje oblikovanje škatle, namenjene shranjevanju zarezanega kruha, in grobo oceno volumna. Oblikovanje škatle je ključnega pomena, saj mora biti popolnoma prilagojeno meram kruha, kar ne zagotavlja le varnega shranjevanja, temveč tudi maksimalno izrabo prostora. Z uporabo osi in izmerjenih dimenzij smo natančno določili obliko in velikost škatle, ki optimalno ustreza geometriji kruha. To je izredno pomembno ne samo za estetski vidik, ampak tudi za praktične namene, kot so lažje pakiranje, boljša organizacija skladiščnih prostorov in učinkovitejša distribucija izdelkov. Poleg tega nam je groba ocena prostornine kruha, pridobljena med tem postopkom, omogočila boljše razumevanje in prilagajanje potrebam embalaže. Rezultate našega dimenzioniranja si lahko ogledamo na sliki 4.4.




Slika 4.4: Dizajnirana je škatla za a) objekt testnega oblaka točk in b) oblak točk krušnega testa.

Zadnji korak, ki nam ostane, je najti način, kako fleksibilno in robustno zarezati kruh glede na uporabnikove zahteve. To dosežemo tako, da omogočimo uporabniku, da sam nastavi število rezov in kot med lokalno osjo y' in trajektorijo zarezovanja. Ta kot, ki smo ga poimenovali α , se lahko giblje v območju od


-90° do 90° oziroma $[-90^\circ, 90^\circ]$. Na ta način omogočamo uporabniku, da prilagodi način zarezovanja krušnega testa na vse možne načine, kar povečuje funkcionalnost in uporabnost sistema.

Prilagoditev kota α uporabniku omogoča izbiro načina zarezovanja, bodisi gre za diagonalne reze, ravne reze ali reze pod poljubnim kotom, kar zagotavlja veliko prilagodljivost pri rezanju krušnega testa. Nastavitev števila rezov pa uporabniku omogoča, da določi, kako tanka ali debela bodo zarezovanja, glede na njegove specifične zahteve. Ta sistem omogoča optimalno zarezovanje testa za različne vrste kruha in zadovoljuje različne preference uporabnikov. Kombinacija teh dveh nastavitev kota α in števila zarezovanj, zagotavlja izjemno prilagodljivost pri zarezovanju testa. V našem primeru smo nastavili kot α na 40° in število zarezovanj na 3. Rezultate teh nastavitev si lahko ogledamo na sliki 4.5.



Slika 4.5: Nastavitev parametrov za zarezovanje, kot $\alpha = 40^\circ$ in število zarezovanj = 3 a) objekt za testiranje, b) krušno testo.

S to funkcionalnostjo postane sistem za zarezovanje testa uporabniku prijazen in izjemno prilagodljiv, kar povečuje učinkovitost postopka rezanja. Na ta način lahko uporabniki prilagodijo rezanje testa natančno svojim potrebam, ne glede na vrsto in obliko testa. Rezultate, pridobljene z algoritmi, ki omogočajo zarezovanje testa, si lahko ogledamo na sliki 4.6, kjer je prikazano, kako bo dejansko potekalo zarezovanje.




Slika 4.6: a) model pripravljen za zarezovanje, b) krušno testo pripravljeno za zarezovanje.

Poleg priprave krušnega testa za peko smo zaradi varnostnih zahtev v laboratoriju sprejeli dodatne ukrepe. Eden od teh ukrepov je bilo povečanje višine zarezovanja, da preprečimo morebitno poškodbo tekočega traku. Ta prilagoditev zagotavlja, da sistem za zarezovanje testa deluje varno in učinkovito tudi v laboratorijskih pogojih, kjer je treba upoštevati dodatne varnostne standarde. S tem smo zagotovili, da so vsi varnostni vidiki upoštevani, kar omogoča nemoten potek eksperimentov in testiranj brez tveganja za poškodbe opreme.

5 Eksperimentalna validacija


V tem poglavju so predstavljeni preizkusi in rezultati, pridobljeni med razvojem robotskega sistema za zarezovanje testa. Varno testiranje je ključno za zagotavljanje zanesljivosti in učinkovitosti sistema, saj lahko nepravilno izvedeni preizkusi ne le popačijo rezultate, temveč tudi povzročijo poškodbe opreme ali celo ogrozijo varnost ljudi.


Testiranje smo začeli v varnem okolju, pri čemer smo namesto noža uporabili konico, da smo zmanjšali tveganje poškodb. Za preverjanje natančnosti smo kot nadomestek za krušno testo uporabili škatlo, kar nam je omogočilo lažje prepoznavanje in odpravljanje morebitnih napak v robotskem sistemu. Na ta način smo zagotovili, da so rezultati testov zanesljivi in ustrezni za nadaljnje izboljšave sistema. Začetno testno postavitev robotskega sistema za zarezovanje testa si lahko ogledamo na sliki 5.1.



Slika 5.1: Testni sistem za zarezovanje testa.

Po zaključku začetnih testov smo prešli na dejansko zarezovanje krušnega testa z robotskim sistemom. Špico smo zamenjali z nožem za zarezovanje testa, namesto škatle pa smo uporabili krušno testo. Glavni cilj preizkusov je bil zagotoviti, da sistem varno, natančno in hitro zarezuje testo, brez tveganja za poškodbe ljudi ali opreme. Poleg natančnosti smo preverjali tudi hitrost in učinkovitost postopka, pri čemer smo upoštevali različne oblike testa, rezalne parametre in pogoje delovanja sistema. Rezultati preizkusov vključujejo podrobnosti o morebitnih izzivih ter izboljšave, ki smo jih izvedli za optimizacijo sistema. Postopek zarezovanja, pri kateri smo nastavili kot $\alpha = 0^\circ$ in število linij zarezovanja na 3, si lahko ogledamo po koraki, označenih od *a)* do *p)*, na sliki 5.2.






Slika 5.2: Potek zarezovanja, kot $\alpha = 0^\circ$ in število linij zarezovanja = 3.

Postopek zarezovanja se izvaja v več korakih: *a)* Najprej je testo postavljeno na tekoči trak, kar predstavlja začetek procesa. *b)* Laserski senzor zazna prisotnost testa (rdeča pika na krušnem testu), tekoči trak se ustavi, kamera zajame sliko in se začne obdelava oblaka točk. *c)* Po prejemu kalibriranih točk se trak ponovno zažene in robot se začne premikati proti prvi točki. *d)* Robot začne z zarezovanjem, *e)* ki se nadaljuje, *f)* dokler ni prva linija zarezovanja dokončana, nakar se robot dvigne. *g)* Robot se nato pripravi za začetek druge linije zarezovanja, *h)* začne z zarezovanjem, *i)* zaključi in *j)* se dvigne, da začne z zarezovanjem tretje linije. *k)* Po začetku zarezovanja tretje linije, *l)* jo robot zaključi, *m)* se robot ponovno dvigne, *n)* in se vrne v začetni položaj. *o)* S tem je postopek zarezovanja zaključen, *p)* zarezano krušno testo pa je pripravljeno za peko.

Zarezovanje testa smo izvedli v različnih položajih, pod različnimi koti in z različnimi oblikami testa, da bi celovito preizkusili delovanje sistema v različnih pogojih. S tem smo želeli ugotoviti, kako se sistem odziva na spremembe v kotu zarezovanja, položaju in obliki testa ter ali lahko ohrani visoko raven natančnosti in kakovosti rezov ne glede na te spremembe. Namen teh preizkusov je bil tudi preveriti prilagodljivost sistema v realnih razmerah, kjer se lahko zahteve glede zarezovanja in oblika kruha spreminjajo. Preizkusi so nam omogočili vpogled v učinkovitost sistema pri različnih konfiguracijah ter prispevali k optimizaciji njegovega delovanja. Rezultate teh preizkusov si lahko ogledamo na sliki 5.3.



Slika 5.3: Tri linije zarezovanja in kot a) $\alpha = 30^\circ$, b) $\alpha = 0^\circ$, c) $\alpha = 30^\circ$.

V sklopu preizkusov smo se osredotočili na čas obdelave podatkov in čas zarezovanja, od začetka procesa do njegovega zaključka. Povprečni čas zarezovanja posamezne linije je bil odvisen od specifičnih zahtev uporabnika ter oblike in velikosti testa. Čas zarezovanja je bil približno 0,65 sekunde na linijo. Čas obdelave oblaka točk in pridobitev kalibriranih točk je bil izjemno učinkovit, saj je sistem v povprečju potreboval manj kot 0,07 sekunde za generiranje potrebnih podatkov. Celoten čas delovanja sistema, od zaznave testa do zaključka zarezovanja, je bil grobo ocenjen na približno 10 sekund, kar potrjuje zmožnost sistema za izvajanje zarezovanja v realnem času z visoko kakovostjo in hitrostjo obdelave. Ti rezultati potrjujejo, da sistem deluje z izjemno učinkovitostjo in zanesljivostjo tudi pri različnih konfiguracijah in zahtevah.

6 Zaključek

V diplomski nalogi smo razvili in uspešno preizkusili robotski sistem za zarezovanje krušnega testa. Ključno vlogo so pri tem igrali algoritmi in filtri, ki smo jih uporabili za natančno filtriranje oblaka točk ter za načrtovanje trajektorij rezanja. Ti postopki so zagotovili, da je sistem zanesljivo sledil načrtovanim linijam zarezovanja ter se učinkovito prilagajal različnim oblikam in legam testa.

Preizkusi so pokazali, da sistem izpolnjuje vse zastavljene zahteve, pri čemer smo se uspešno izognili tveganjem za poškodbe opreme in osebja. Prilagoditve sistema, ki vključujejo različne kote in položaje, so omogočile zanesljivo delovanje sistema v različnih pogojih, kar potrjuje njegovo prilagodljivost in učinkovitost.

Na podlagi pridobljenih rezultatov smo ugotovili, da je razviti sistem primeren za uporabo v industrijskem okolju, kjer so potrebni varni, natančni in prilagodljivi robotski sistemi za obdelavo hrane.

6.1 Možne izboljšave za prihodnosti

Čeprav je robotski sistem za zarezovanje krušnega testa dosegel visoko stopnjo zanesljivosti in učinkovitosti, obstajajo priložnosti za nadaljnje izboljšave. Ena izmed ključnih smeri prihodnjega razvoja vključuje uporabo strojnega učenja in globokega učenja za še boljšo prilagoditev sistema specifičnim pogojem in potrebam.

Strojno učenje bi omogočilo, da se sistem sčasoma uči iz prejšnjih izkušenj in na podlagi teh podatkov optimizira rezalne poti. Na ta način bi sistem lahko bolje razumel lastnosti različnih vrst testa, kot so oblika, tekstura in gostota, ter se dinamično prilagajal za doseganje večje natančnosti in konsistentnosti rezov.

Globoko učenje, ki temelji na nevronskih mrežah, bi lahko izboljšalo načrtovanje trajektorij in filtriranje oblaka točk. S prepoznavanjem vzorcev v podatkih bi sistem natančneje določil optimalne rezalne poti in se prilagajal spremembam v obliki in položaju testa. To bi omogočilo, da sistem vedno deluje na optimalni ravni, ne glede na spreminjajoče se pogoje.

Poleg tega bi uvedba avtomatizirane kalibracije in vzdrževanja sistema zmanjšala potrebo po ročnem poseganju, kar bi povečalo zanesljivost in učinkovitost sistema. S tem bi sistem postal še bolj prilagodljiv in primeren za uporabo v različnih industrijskih okoljih, kjer je potrebna visoka stopnja avtomatizacije in natančnosti.

Literatura

- [1] I. Rokhim, N. J. Ramadhan in T. Rusdiana, “Image processing based ur5e manipulator robot control in pick and place application for random position and orientation of object,” v *2021 3rd International Symposium on Material and Electrical Engineering Conference (ISMEE)*, str. 124–130, IEEE, 2021.
- [2] L. Jurdziak, R. Blazej in M. Bajda, “Conveyor belt 4.0,” v *Intelligent Systems in Production Engineering and Maintenance*, str. 645–654, Springer, 2019.
- [3] C. Mertz, L. E. Navarro-Serment, R. MacLachlan, P. Rybski, A. Steinfeld, A. Suppe, C. Urmson, N. Vandapel, M. Hebert, C. Thorpe *et al.*, “Moving object detection with laser scanners,” *Journal of Field Robotics*, vol. 30, no. 1, str. 17–43, 2013.
- [4] R. Rahim, S. Aryza, P. Wibowo, A. K. Z. Harahap, A. R. Suleman, E. E. Sihombing, Y. Harputra, M. R. Rambe, A. P. U. Siahaan, H. Hermansyah *et al.*, “Prototype file transfer protocol application for lan and wi-fi communication,” *Int. J. Eng. Technol*, vol. 7, no. 2.13, str. 345–347, 2018.
- [5] J.-D. Decotignie, “Ethernet-based real-time and industrial communications,” *Proceedings of the IEEE*, vol. 93, no. 6, str. 1102–1117, 2005.
- [6] B. A. Forouzan, *TCP/IP protocol suite*. McGraw-Hill Higher Education, 2002.
- [7] A. Elatta, L. P. Gen, F. L. Zhi, Y. Daoyuan in L. Fei, “An overview of robot calibration,” *Information Technology Journal*, vol. 3, no. 1, str. 74–78, 2004.

-
- [8] Q. Zhao, X. Gao, J. Li in L. Luo, “Optimization algorithm for point cloud quality enhancement based on statistical filtering,” *Journal of Sensors*, vol. 2021, no. 1, str. 7325600, 2021.
 - [9] Y. Duan, C. Yang in H. Li, “Low-complexity adaptive radius outlier removal filter based on pca for lidar point cloud denoising,” *Applied Optics*, vol. 60, no. 20, str. E1–E7, 2021.
 - [10] H. Zhang, Z. Duan, N. Zheng, Y. Li, Y. Zeng in W. Shi, “An efficient class-constrained dbscan approach for large-scale point cloud clustering,” *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 15, str. 7323–7332, 2022.
 - [11] K.-L. Wu in M.-S. Yang, “Mean shift-based clustering,” *Pattern Recognition*, vol. 40, no. 11, str. 3035–3052, 2007.
 - [12] N. Goel, H. Kaur in J. Saxena, “Modified decision based unsymmetric adaptive neighborhood trimmed mean filter for removal of very high density salt and pepper noise,” *Multimedia Tools and Applications*, vol. 79, str. 19739–19768, 2020.
 - [13] E. A. L. Narváez in N. E. L. Narváez, “Point cloud denoising using robust principal component analysis,” v *International Conference on Computer Graphics Theory and Applications*, vol. 2, str. 51–58, SCITEPRESS, 2006.
 - [14] C. Qu, Y. Zhang, K. Huang, S. Wang in Y. Yang, “Point clouds outlier removal method based on improved mahalanobis and completion,” *IEEE Robotics and Automation Letters*, vol. 8, no. 1, str. 17–24, 2022.
 - [15] S. Laine in T. Karras, “Efficient sparse voxel octrees,” v *Proceedings of the 2010 ACM SIGGRAPH symposium on Interactive 3D Graphics and Games*, str. 55–63, 2010.
 - [16] N. Dyn, A. Iske in H. Wendland, “Meshfree thinning of 3d point clouds,” *Foundations of computational Mathematics*, vol. 8, str. 409–425, 2008.
 - [17] J. Li, J. Zhou, Y. Xiong, X. Chen in C. Chakrabarti, “An adjustable farthest point sampling method for approximately-sorted point cloud data,” v *2022 IEEE Workshop on Signal Processing Systems (SiPS)*, str. 1–6, IEEE, 2022.

-
- [18] Q. Xie in X. Xie, “Point cloud data reduction methods of octree-based coding and neighborhood search,” v *Proceedings of 2011 International Conference on Electronic & Mechanical Engineering and Information Technology*, vol. 7, str. 3800–3803, IEEE, 2011.
- [19] D. Shan, Y. Zhang, X. Wang, W. Luo, X. Meng, Y. Liu in X. Gao, “An efficient point cloud semantic segmentation method based on bilateral enhancement and random sampling,” *Electronics*, vol. 12, no. 24, str. 4927, 2023.
- [20] L. Fan in P. M. Atkinson, “An iterative coarse-to-fine sub-sampling method for density reduction of terrain point clouds,” *Remote Sensing*, vol. 11, no. 8, str. 947, 2019.
- [21] H. Jiang, W. Sun, Y. Shi in Y. Huang, “A study and implementation on the data reduction based on the curvature of points clouds [j],” *Computer Modeling and New Technologies*, vol. 18, no. 3, str. 104–110, 2014.
- [22] R. Raguram, J.-M. Frahm in M. Pollefeys, “A comparative analysis of ransac techniques leading to adaptive real-time random sample consensus,” v *Computer Vision–ECCV 2008: 10th European Conference on Computer Vision, Marseille, France, October 12–18, 2008, Proceedings, Part II 10*, str. 500–513, Springer, 2008.
- [23] R. Hulik, M. Spanel, P. Smrz in Z. Materna, “Continuous plane detection in point-cloud data based on 3d hough transform,” *Journal of visual communication and image representation*, vol. 25, no. 1, str. 86–97, 2014.
- [24] A.-V. Vo, L. Truong-Hong, D. F. Laefer in M. Bertolotto, “Octree-based region growing for point cloud segmentation,” *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 104, str. 88–100, 2015.
- [25] H. H. Nguyen, J. Kim, Y. Lee, N. Ahmed in S. Lee, “Accurate and fast extraction of planar surface patches from 3d point cloud,” v *Proceedings of the 7th International Conference on Ubiquitous Information Management and Communication*, str. 1–8, 2013.

-
- [26] L. Liu, X. Tu, Q. Yang in J. Yu, “Fast planar surface detection in point clouds using voxel-grid-center-constrained iterative adaptive plane extraction,” v *2021 40th Chinese Control Conference (CCC)*, str. 7343–7348, IEEE, 2021.
- [27] C. Kang, T. Lu, M. Zong, F. Wang in Y. Cheng, “Point cloud smooth sampling and surface reconstruction based on moving least squares,” *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. 42, str. 145–151, 2020.
- [28] Y. Li in L. Liu, “Enhancing diffusion-based point cloud generation with smoothness constraint,” *arXiv preprint arXiv:2404.02396*, 2024.
- [29] F. Yan, F. Wang, Y. Guo in P. Jiang, “Saliency-guided smoothing for 3d point clouds,” v *International Conference on Intelligent Computing*, str. 165–174, Springer, 2017.
- [30] J. Digne in C. De Franchis, “The bilateral filter for point clouds,” *Image Processing On Line*, vol. 7, str. 278–287, 2017.
- [31] H. H. Afshari, S. A. Gadsden in S. Habibi, “Gaussian filters for parameter and state estimation: A general review of theory and recent trends,” *Signal Processing*, vol. 135, str. 218–238, 2017.
- [32] P. M. Narendra, “A separable median filter for image noise smoothing,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, no. 1, str. 20–29, 1981.
- [33] H. Huang, S. Wu, M. Gong, D. Cohen-Or, U. Ascher in H. Zhang, “Edge-aware point set resampling,” *ACM transactions on graphics (TOG)*, vol. 32, no. 1, str. 1–12, 2013.
- [34] H. Abdi in L. J. Williams, “Principal component analysis,” *Wiley interdisciplinary reviews: computational statistics*, vol. 2, no. 4, str. 433–459, 2010.
- [35] S. Oomori, T. Nishida in S. Kurogi, “Point cloud matching using singular value decomposition,” *Artificial Life and Robotics*, vol. 21, str. 149–154, 2016.

- [36] C.-H. Lin, J.-Y. Chen, P.-L. Su in C.-H. Chen, “Eigen-feature analysis of weighted covariance matrices for lidar point cloud classification,” *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 94, str. 70–79, 2014.